Rapport de Recherche et de Travaux Pratiques : De l'Interprétabilité Intrinsèque à l'Explicabilité des Systèmes d'Ensemble

Introduction Générale aux Enjeux de la Transparence Algorithmique

L'évolution paradigmatique de l'apprentissage automatique a franchi une étape décisive avec l'émergence de modèles à très haute capacité de représentation, tels que les réseaux de neurones profonds et les architectures d'apprentissage d'ensemble (Multiple Classifier Systems - MCS). Ces systèmes permettent d'atteindre des niveaux de performance prédictive inédits, mais ils engendrent invariablement une opacité structurelle qualifiée de problème de la « boîte noire ».[1] Dans des environnements décisionnels à haut risque, tels que le diagnostic médical, la finance quantitative ou la justice pénale, la validité d'une décision automatisée ne peut plus reposer exclusivement sur des métriques de performance purement statistiques, telles que l'exactitude (accuracy) ou l'aire sous la courbe (AUC). Elle exige une compréhensibilité, une justifiabilité et une traçabilité rigoureuses des processus inférentiels.[1]

L'explicabilité de l'intelligence artificielle (Explainable AI - XAI) constitue le champ scientifique visant à établir une correspondance intelligible, formelle et auditable entre les données d'entrée, les transformations mathématiques internes du modèle et la décision finale.[1] Le présent rapport est conçu comme une exploration exhaustive, structurée sous la forme d'un guide de travaux pratiques (TP) de niveau recherche. Cette progression analytique s'articule autour de quatre axes méthodologiques fondamentaux : l'interprétabilité intrinsèque des modèles par conception, l'explicabilité post-hoc des modèles simples et opaques, l'explicabilité spécifique aux architectures de combinaison (notamment le bagging et le boosting), et enfin, l'exploration de cadres avancés incluant le méta-apprentissage (stacking), la sélection dynamique de classifieurs et l'analyse contrefactuelle.

Pour ancrer cette exploration théorique dans une réalité empirique tangible, l'ensemble des cas d'étude pratiques développés dans ce rapport s'appuie sur la problématique de la prédiction de la maladie rénale chronique (Chronic Kidney Disease - CKD). Ce jeu de données de référence, issu du référentiel de l'Université de Californie à Irvine (UCI Machine Learning Repository), contient 400 instances de patients, chacune caractérisée par 24 variables cliniques distinctes.[6] Ces variables se divisent en 11 attributs numériques continus (tels que le taux d'hémoglobine, la pression artérielle, la créatinine sérique et l'azote uréique du sang) et 13 attributs catégoriels (tels que la présence de diabète sucré, d'hypertension ou d'anémie).[6]

L'utilisation de ces données médicales complexes illustre de manière critique l'impératif de l'explicabilité : une décision diagnostique engageant le pronostic vital ou le parcours thérapeutique d'un patient ne peut en aucun cas être acceptée par le corps médical sans une justification causale transparente et physiologiquement cohérente.[1]

Phase Préparatoire : Traitement des Données et Architecture du Cas Pratique

Avant de déployer les modèles d'apprentissage automatique et les algorithmes d'explicabilité, le jeu de données CKD requiert un traitement rigoureux et méthodique. Les données médicales issues de cohortes réelles sont intrinsèquement imparfaites et présentent de multiples défis, notamment une forte prévalence de valeurs manquantes et un déséquilibre structurel des classes cibles.[6] L'ingénierie des caractéristiques débute par une stratégie d'imputation sophistiquée. L'analyse des données révèle que la suppression des observations incomplètes réduirait drastiquement la puissance statistique de la cohorte. Par conséquent, les méthodes optimales recommandent l'utilisation de l'algorithme des k-plus proches voisins (KNN Imputer) pour estimer et remplacer les valeurs manquantes des variables numériques continues, en s'appuyant sur la similarité euclidienne entre les profils des patients.[6] Pour les variables catégorielles, une imputation par le mode (la valeur la plus fréquente) est privilégiée pour maintenir la distribution de base.[6]

Une fois les données nettoyées, il est crucial d'adresser le déséquilibre des classes, la cohorte présentant généralement un biais vers la classe positive (patients atteints de CKD) ou négative selon les sous-échantillons étudiés.[3] L'entraînement d'un algorithme sur des données fortement déséquilibrées conduit à un biais de prédiction, le modèle tendant à ignorer la classe minoritaire pour maximiser son exactitude globale. L'application de la technique de suréchantillonnage des minorités synthétiques (SMOTE - Synthetic Minority Over-sampling Technique) permet de générer des exemples synthétiques de la classe minoritaire en interpolant de nouveaux points dans l'espace des caractéristiques entre les instances existantes les plus proches.[3] Cette approche rééquilibre la distribution des classes avant l'entraînement, garantissant que le modèle capture les motifs discriminants des deux catégories de patients.[3]

Les données sont ensuite standardisées à l'aide de techniques de mise à l'échelle robuste pour limiter l'influence des valeurs aberrantes (outliers) cliniques, puis divisées en utilisant un partitionnement stratifié (stratified train-test split). Ce partitionnement garantit que les proportions exactes des classes de la maladie rénale chronique sont maintenues entre les ensembles d'apprentissage (alloués à 70% ou 80% des données) et de test (20% à 30%), permettant ainsi une évaluation non biaisée des capacités de généralisation des modèles.[6]

Cas Pratique 1 : Interprétabilité Intrinsèque des

Modèles

La première étape de cette exploration pratique se concentre sur les modèles d'apprentissage automatique dits « Glass-Box » (boîtes de verre), dont l'architecture mathématique est nativement transparente. Dans ce paradigme, l'interprétabilité n'est pas rajoutée a posteriori, mais constitue une propriété structurelle interne au modèle lui-même.[1] Un modèle est considéré comme intrinsèquement interprétable si un expert humain peut appréhender son fonctionnement global et simuler mentalement le calcul menant à une prédiction spécifique.[1]

Les Modèles Linéaires et Arborescents Simples

Le point de départ naturel du cas pratique repose sur l'implémentation d'une régression logistique pénalisée. Ce modèle statistique classique évalue la probabilité d'occurrence de la maladie rénale chronique via une fonction sigmoïde appliquée à une combinaison linéaire des variables d'entrée. Formellement, la probabilité conditionnelle s'exprime par l'équation $P(y=1|x) = \sigma(w^\top x + b)$, où $\sigma(z) = \frac{1}{1+e^{-z}}$.[1] L'avantage fondamental de cette architecture réside dans la lisibilité directe de ses paramètres. Les coefficients pondéraux w_i représentent l'influence (le log-odds ratio) de chaque variable biomédicale de manière indépendante.[1]

Dans la pratique, l'entraînement de la régression logistique sur le jeu de données CKD via la bibliothèque scikit-learn en Python permet d'extraire immédiatement un vecteur de coefficients. L'analyse de ces poids révèle instantanément quels biomarqueurs augmentent ou diminuent le risque pathologique. Par exemple, l'observation d'un coefficient fortement négatif associé au taux d'hémoglobine ou à la gravité spécifique de l'urine indique clairement au médecin que la diminution physiologique de ces valeurs accroît de manière exponentielle la probabilité de développer la maladie. Bien que sa transparence soit totale, ce modèle souffre d'un biais élevé : il postule une relation strictement linéaire et additive entre les caractéristiques et le log-odds de la cible, échouant ainsi à capturer les interactions complexes (par exemple, l'effet combiné d'un âge avancé et de l'hypertension).[1]

Pour pallier l'absence de modélisation des interactions tout en conservant l'interprétabilité, le cas pratique évolue vers l'entraînement d'un arbre de décision (Classification and Regression Trees - CART). Un arbre de décision, lorsqu'il est contraint à une faible profondeur (typiquement limitée à 3 ou 4 niveaux), offre une structure de règles logiques propositionnelles parfaitement intelligibles.[1] Le modèle segmente itérativement l'espace des patients par des frontières de décision orthogonales, sélectionnant à chaque nœud la caractéristique qui maximise le gain d'information (ou minimise l'impureté de Gini).[14] La visualisation de l'arbre, générée via des bibliothèques telles que graphviz ou dtreeviz, produit un graphe orienté où chaque chemin de la racine à une feuille constitue une règle explicite, par exemple : "SI la gravité spécifique de l'urine est inférieure à 1.015 ET le taux d'hémoglobine est inférieur à 10 g/dL ALORS le diagnostic est Positif pour la CKD avec une probabilité de 95%".[1] Néanmoins,

l'interprétabilité d'un arbre de décision s'effondre rapidement dès lors que sa profondeur augmente pour tenter de capturer des relations plus fines, le transformant rapidement en un enchevêtrement de règles incompréhensibles souffrant d'une variance extrême et d'une propension au surapprentissage.[1]

Les Machines de Boosting Explicables (Explainable Boosting Machines - EBM)

Pour surmonter le mythe du compromis strict entre la performance prédictive absolue et la compréhension humaine, le TP introduit une architecture novatrice : les Explainable Boosting Machines (EBM). L'EBM, développée par Microsoft Research, représente une avancée majeure et s'inscrit dans le cadre mathématique des Modèles Additifs Généralisés avec Interactions (GA2M).[1] L'hypothèse fondamentale de prédiction de l'EBM s'exprime sous la forme :

$$g(\mathbb{E}[y]) = \beta_0 + \sum_{j=1}^{d} f_j(x_j) + \sum_{i \neq j} f_{ij}(x_i, x_j)$$

Dans cette formulation, g représente la fonction de lien (logit pour la classification binaire de la CKD), f_j capture l'effet non linéaire univarié de la variable j, et f_{ij} modélise les interactions bidimensionnelles les plus significatives automatiquement détectées par l'algorithme.[1]

La clé de l'interprétabilité de l'EBM réside dans son processus d'entraînement spécifique, appelé boosting cyclique (round-robin).[1] Contrairement au gradient boosting traditionnel qui construit des arbres de décision multivariés profonds, l'EBM entraîne séquentiellement un micro-arbre d'une profondeur maximale d'un seul nœud (stump) en se restreignant à une seule caractéristique à la fois.[1] L'algorithme itère sur l'ensemble des caractéristiques avec un taux d'apprentissage extrêmement faible, mettant à jour les fonctions de forme f_j de manière purement additive. Ce processus isole formellement l'effet marginal de chaque variable clinique tout en neutralisant les effets de la colinéarité, garantissant que l'ordre des caractéristiques n'affecte pas le résultat.[1]

Caractéristique	**Régression Logistique**	**Arbre de Décision (Profond)**	**Explainable Boosting Machine (EBM)**
Topologie	Combinaison linéaire stricte	Partitionnement hiérarchique complexe	Additif cyclique (Stumps univariés)

Interactions	Aucune (sauf ingénierie manuelle)	Illimitées, locales et enchevêtrées	Détectées automatiquement et limitées aux paires [1]
Nature de l'Explicabilité	Lecture directe des coefficients	Inspection visuelle complexe des chemins	Fonctions de forme univariées exactes (2D) [1]
Performance Prédictive	Faible à Modérée	Modérée (risque de surapprentissage)	Très Élevée (équivalente à Random Forest) [1]

Dans l'implémentation de ce cas pratique via la bibliothèque Python interpretml [17], l'instance EbmClassification est ajustée sur le jeu de données des patients CKD. L'analyse des résultats démontre de manière empirique que l'EBM atteint des performances discriminatives comparables aux modèles de boîte noire de référence comme XGBoost (souvent supérieures à 94% d'exactitude et à 0,95 d'AUC sur le jeu UCI) tout en permettant une inspection visuelle directe et sans ambiguïté.[1] Le rapport généré par la méthode explain_global() de l'EBM produit une interface où chaque fonction $f_j(x_j)$ se comporte comme une table de correspondance exacte.[18] Le clinicien peut observer une courbe graphique bidimensionnelle illustrant l'augmentation précise du log-odds de la CKD au fur et à mesure de l'évolution de la pression artérielle ou de l'âge du patient, sans aucune approximation post-hoc ni perte de fidélité.[1] L'EBM incarne ainsi le paradigme de la transparence par conception, prouvant que l'opacité n'est pas une fatalité pour atteindre la haute performance.

Cas Pratique 2 : Explicabilité Post-Hoc des Modèles Simples et Opaques

Lorsque les relations fonctionnelles sous-jacentes d'un problème médical requièrent des algorithmes à très haute capacité tels que les réseaux de neurones profonds (Perceptrons Multicouches - MLP) ou des machines à vecteurs de support (SVM) à noyaux non linéaires, l'interprétabilité intrinsèque est définitivement sacrifiée au profit de la modélisation.[1] Le système devient une boîte noire totale. Il convient alors de recourir à des méthodes d'explicabilité post-hoc. Ces méthodes agissent comme une couche fonctionnelle d'ingénierie externe qui cherche à projeter le comportement décisionnel opaque dans un espace de représentation compréhensible par l'humain, sans jamais altérer les paramètres ou la structure du modèle original.[1]

Explicabilité Locale par Perturbation : L'approche LIME

Le framework LIME (Local Interpretable Model-agnostic Explanations) vise à justifier une prédiction algorithmique individuelle en générant un voisinage de données synthétiques autour de l'instance spécifique d'intérêt, et en y ajustant un modèle interprétable localement équivalent (tel qu'une régression linéaire régularisée de type Ridge ou Lasso).[1]

La mécanique mathématique de LIME cherche à optimiser une fonction objectif précise : $g^* = \arg\min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$ Dans cette équation, f représente le modèle opaque global (par exemple, le réseau de neurones prédisant la CKD), g est le modèle explicatif simple appartenant à la classe de fonctions G, π_x est un noyau de pondération (typiquement gaussien) mesurant la proximité mathématique des points de données perturbés par rapport au patient évalué, et $\Omega(g)$ introduit une pénalité limitant la complexité de l'explication (afin d'assurer que l'explication finale ne comporte que quelques variables humainement assimilables).[1]

Dans le cadre du TP sur le diagnostic CKD, LIME est instancié via la bibliothèque Python lime. Un profil patient spécifique, prédit par le réseau de neurones avec une probabilité alarmante de 0,98 d'être atteint de maladie rénale chronique, est sélectionné.[6] L'algorithme génère des milliers de permutations des caractéristiques cliniques de ce patient (modifiant aléatoirement l'âge, la créatinine, le taux de sucre) et interroge le modèle opaque pour observer les variations de probabilité de prédiction. LIME ajuste ensuite sa régression pondérée et restitue un diagramme à barres horizontal. Ce diagramme démontre visuellement que, pour ce patient unique dans son contexte local, c'est la combinaison d'une gravité spécifique de l'urine fixée à 1.010 et d'un taux d'hémoglobine bas à 9.2 g/dL qui constitue le principal moteur causal de la décision clinique du réseau de neurones.[1]

Cependant, l'investigation empirique rigoureuse révèle une limite systémique et critique de LIME, particulièrement exacerbée sur les données médicales tabulaires complexes : l'instabilité de l'explication locale.[1] L'espace des caractéristiques d'un modèle non linéaire comporte de nombreuses discontinuités abruptes. Lorsque LIME génère ses perturbations gaussiennes, l'échantillonnage aléatoire peut franchir ces frontières de décision de manière erratique. Conséquence directe : deux exécutions successives de l'algorithme LIME sur le même profil patient peuvent engendrer des vecteurs d'importances de variables radicalement divergents.[1] Dans le domaine de la santé, cette instabilité de l'explication est rédhibitoire, car un médecin ne peut fonder un protocole thérapeutique sur une justification algorithmique non reproductible.[1]

Explicabilité Globale et Fondations Issues de la Théorie des Jeux : L'approche SHAP

Pour pallier structurellement l'instabilité de LIME et fournir des garanties mathématiques inébranlables d'équité, de cohérence et de nullité, la méthode SHAP (SHapley Additive

exPlanations) est intégrée au pipeline d'évaluation post-hoc.[1] Profondément ancrée dans la théorie des jeux coopératifs formulée par Lloyd Shapley, la méthode SHAP considère chaque prédiction du modèle d'apprentissage automatique comme un « gain » à distribuer équitablement entre les variables d'entrée, qui agissent comme des « joueurs » formant des coalitions.[1]

La valeur de Shapley d'une caractéristique clinique j est formellement définie par la moyenne pondérée de ses contributions marginales à travers l'ensemble des sous-ensembles possibles de variables : $\phi_j(f, x) = \sum_{S \subseteq \mathcal{F} \setminus \{j\}} \frac{|S|!(|\mathcal{F}|-|S|-1)!}{|\mathcal{F}|!}$ où $\mathcal{F}$ représente l'ensemble complet des 24 variables biomédicales du patient, et f_S désigne l'évaluation du modèle restreint aux variables de la coalition S (les variables absentes étant marginalisées par espérance mathématique).[1]

SHAP offre une propriété mathématique unique et fondamentale : l'additivité locale (ou efficacité).[1] La somme de l'ensemble des valeurs SHAP attribuées aux caractéristiques d'un patient correspond exactement à la différence entre la prédiction individuelle du modèle pour ce patient et la prédiction moyenne du modèle sur l'ensemble de la population de référence.

Critère d'Évaluation	**LIME (Local Interpretable Model-agnostic Explanations)**	**SHAP (SHapley Additive exPlanations)**
Fondation Théorique	Approximation par modèle de substitution local (Surrogate)	Théorie des jeux coopératifs (Valeurs de Shapley) [1]
Stabilité des Explications	Faible (dépendante de l'échantillonnage gaussien local) [1]	Très Élevée (garantie mathématique d'unicité et de consistance)
Additivité Exacte	Non garantie	Garantie mathématiquement (Propriété d'Efficacité) [1]
Coût Computationnel	Modéré	Très Élevé (pour la méthode KernelSHAP agnostique) $O(2^M)$ [1]

Portée de l'Analyse	Exclusivement locale	Locale et Globale (via l'agrégation des valeurs SHAP individuelles) [1]

Dans le déroulement du TP, le calcul des valeurs SHAP est orchestré en Python via l'objet shap.KernelExplainer pour le réseau de neurones.[24] L'analyse globale générée, magnifiquement visualisable au travers d'un graphique en essaim (beeswarm plot ou summary_plot), offre une radiographie complète du comportement de la boîte noire. Ce graphique démontre de façon irréfutable que des valeurs physiologiquement réduites de la gravité spécifique de l'urine et du taux d'hémoglobine, couplées à des niveaux pathologiquement élevés de créatinine sérique, poussent universellement la probabilité de prédiction vers la classe positive pour la maladie rénale chronique à travers l'ensemble de la cohorte de test.[1] La convergence parfaite entre l'expertise médicale attendue et l'explication globale de SHAP permet de sceller la confiance (trust) dans le déploiement opérationnel du modèle opaque.[3]

Cas Pratique 3 : Explicabilité des Modèles de Combinaison (Bagging et Boosting)

L'utilisation systématique de systèmes multi-classifieurs (Ensemble Learning) constitue le paradigme dominant de l'apprentissage automatique moderne pour maximiser la robustesse prédictive et minimiser les erreurs de généralisation sur des données complexes.[1] Ces approches, qui dominent les compétitions de type Kaggle et les applications industrielles critiques, se divisent principalement en méthodes parallèles (Bagging) et séquentielles (Boosting).[1]

Leur efficacité empirique s'appuie sur des justifications théoriques profondes. Le théorème du jury de Condorcet démontre que l'agrégation par vote majoritaire de décisions issues de classifieurs indépendants et faiblement compétents (ayant une probabilité de succès $p > 0,5$) fait converger la probabilité d'une décision collective correcte asymptotiquement vers 1 lorsque la taille de l'ensemble croît.[1] D'un point de vue statistique, l'identité de Krogh-Vedelsby postule formellement que l'erreur quadratique d'un ensemble de modèles est rigoureusement égale à la moyenne des erreurs individuelles diminuée de la diversité (l'ambiguïté ou la variance des prédictions) entre ces modèles.[1]

Cependant, cette agrégation provoque un phénomène redoutable pour la transparence : l'explosion combinatoire de la dimension de Vapnik-Chervonenkis (dimension VC). Une Forêt Aléatoire composée de centaines d'arbres génère une frontière de décision en escalier d'une complexité massive, rendant la décomposabilité et la simulabilité mentale humainement impossibles. Le modèle devient une boîte noire structurelle.[1]

Scénario Bagging : Forêts Aléatoires, TreeSHAP et Extraction de

Règles Stables (SIRUS)

Le bagging (Bootstrap Aggregating) vise principalement à réduire la variance de la prédiction en entraînant de multiples apprenants instables, tels que des arbres de décision non élagués, sur des sous-échantillons de données tirés aléatoirement avec remise depuis le jeu de données d'origine.[1] Dans le cadre du diagnostic de la maladie rénale chronique, l'entraînement d'une forêt aléatoire de 500 arbres fournit une prédiction d'une fiabilité exceptionnelle, imperméable au bruit statistique, mais elle engendre une myriade de chemins décisionnels locaux souvent contradictoires.[1]

Pour interpréter avec exactitude cette forêt aléatoire, le calcul de la méthode SHAP agnostique (KernelSHAP) s'avère mathématiquement rédhibitoire en raison de sa complexité exponentielle en $O(2^M)$, nécessitant l'évaluation d'un nombre incalculable de coalitions de variables.[1] La solution apportée dans ce cas pratique est l'utilisation de l'algorithme TreeSHAP. Conçu spécifiquement pour les ensembles arborescents, TreeSHAP exploite l'architecture interne des arbres pour calculer les valeurs de Shapley exactes avec une complexité drastiquement réduite à un temps polynomial $O(T \cdot L \cdot D^2)$ (où T désigne le nombre d'arbres, L le nombre maximal de feuilles, et D la profondeur maximale).[1] En naviguant dans la structure nodale de la forêt via une programmation dynamique de mémorisation des chemins, TreeSHAP restitue instantanément l'attribution causale exacte de chaque variable clinique à la décision finale.[1]

Une approche radicalement différente pour désopacifier un modèle de bagging consiste à opérer une distillation symbolique via l'algorithme SIRUS (Stable and Interpretable RUle Set).[1] L'instabilité pathologique des algorithmes extracteurs de règles classiques provient des perturbations infimes introduites par le rééchantillonnage bootstrap, modifiant la variable de séparation dès la racine de l'arbre et modifiant toute la topologie subséquente.[1] SIRUS contourne brillamment cette limite structurelle en contraignant les divisions (splits) des nœuds des arbres sur une grille prédéfinie de quantiles empiriques de la distribution marginale des données (par exemple les déciles, $q = 10$).[1] L'algorithme extrait ensuite tous les chemins de l'ensemble de la forêt et applique un filtre fréquentiel pour ne conserver que les règles logiques apparaissant le plus régulièrement à travers les multiples arbres.[1] Les règles linéairement redondantes sont éliminées, et les pondérations finales de ce comité de règles restreint sont optimisées via une régression pénalisée de type Ridge.[1]

L'implémentation pratique de SIRUS sur le jeu de données de la maladie rénale via la bibliothèque Python imodels (ou via le package Julia/R dédié) permet d'extraire un ensemble décisionnel extrêmement stable et d'une concision remarquable (généralement contraint à une dizaine de règles courtes).[1] La stabilité de cet ensemble est validée mathématiquement par l'indice de Dice-Sørensen, mesurant le chevauchement des règles extraites sur des échantillons de données indépendants, et atteignant couramment des scores supérieurs à 0,95.[1] Le clinicien

obtient ainsi un artefact interprétable sous la forme de règles propositionnelles explicites et médicalement actionnables ("SI hémoglobine $\leq$ 10 g/dL ET gravité spécifique $\leq$ 1.015 ALORS risque de CKD = Élevé"), conservant la majorité de la capacité de généralisation de la forêt aléatoire d'origine tout en respectant les exigences les plus strictes d'auditabilité réglementaire.[1]

Scénario Distillation de Connaissances : De la Forêt à l'Arbre Unique

En complément de SIRUS, le TP explore la méthodologie de la distillation de connaissances (Knowledge Distillation).[1] Cette architecture d'explicabilité globale vise à transférer la logique décisionnelle encapsulée dans un modèle de haute capacité, qualifié de modèle « enseignant » (la forêt aléatoire de 500 arbres), vers un modèle « étudiant » de structure par essence interprétable (un arbre de décision unique).[40]

Le protocole expérimental en Python procède en trois séquences distinctes. Premièrement, la forêt aléatoire est entraînée de manière classique sur l'ensemble d'apprentissage et optimise ses performances discriminatives (atteignant un score F1 proche de 0,98).[40] Deuxièmement, le jeu de données entier, incluant de manière contre-intuitive l'ensemble de test, subit une procédure de ré-étiquetage (relabeling). La variable cible réelle de diagnostic est remplacée par les vecteurs de probabilités continues (soft labels) générés en prédiction par la forêt aléatoire.[40] Ces étiquettes douces agissent comme un vecteur d'information enrichi, encapsulant la confiance interne de l'ensemble et sa perception de la similarité inter-classes (le « dark knowledge ») de manière bien plus granulaire qu'une simple classification binaire.[1]

Enfin, un estimateur DecisionTreeClassifier standard est ajusté sur cet espace de caractéristiques ré-étiqueté. Il est instruit de maximiser son ajustement aux décisions probabilistes de la forêt sans aucune pénalité de régularisation initiale (profondeur maximale illimitée, min_samples_leaf=1), le forçant ainsi à surapprendre délibérément la distribution non linéaire imitée de l'ensemble.[40] Bien que le processus de distillation garantisse un mimétisme quasi-parfait sur les données historisées, le modèle étudiant est ensuite élagué (pruning) pour retrouver une taille humainement lisible. Sur des données médicales futures invisibles, l'évaluation révèle que cet arbre de décision étudiant préserve de manière étonnante l'architecture décisionnelle de son enseignant, au prix d'une perte d'exactitude minime, tout en offrant au praticien hospitalier un arbre compact, visualisable hors-ligne et totalement indépendant de la charge computationnelle de la forêt d'origine lors de son déploiement en production.[1]

Scénario Boosting : XGBoost et la Complexité de l'Accumulation des Résidus

La famille des algorithmes de Gradient Boosting, implémentée via des bibliothèques hautement optimisées telles que XGBoost ou LightGBM, opère selon un paradigme de

croissance séquentielle par correction d'erreurs.[1] Le Boosting construit une fonction d'approximation de manière purement additive. À chaque itération t, le nouvel apprenant faible h_t (généralement un arbre de décision peu profond) n'est pas ajusté pour modéliser la cible directe, mais est entraîné spécifiquement sur les pseudo-résidus de l'étape précédente. Ces résidus correspondent très exactement au gradient négatif de la fonction de perte globale évalué sur les prédictions du modèle agrégé F_{t-1}.[1] Mathématiquement, la prédiction finale à l'itération T équivaut à la sommation pondérée : $F_T(x) = \sum_{t=1}^{T} \eta \cdot h_t(x)$ où η contrôle le taux d'apprentissage (shrinkage).[1]

Ce mécanisme correctif ciblé réduit implacablement le biais du modèle global, permettant à XGBoost d'atteindre des performances record sur des données tabulaires. Sur le jeu de données CKD combiné à une optimisation SMOTE, l'algorithme frôle souvent la perfection avec une exactitude oscillant entre 96% et 99%.[3] Néanmoins, l'interprétation d'une prédiction finale requiert désormais de justifier conceptuellement non seulement le signal principal capturé par le premier arbre, mais également l'influence accumulée d'une cascade de centaines de micro-corrections locales (les arbres subséquents), dont certaines compensent des erreurs sur des sous-régions extrêmement circonscrites de l'espace des données.[1] Sans une régularisation paramétrique stricte, le modèle mémorise des artéfacts ou du bruit statistique local, et l'explication extraite perd toute substance de causalité médicale.[1]

Face à ce défi structurel, l'utilisation couplée de l'algorithme TreeSHAP sur XGBoost s'avère non seulement recommandée, mais indispensable pour restituer une explicabilité fidèle.[1] Outre les valeurs d'importance marginales, l'API TreeSHAP permet d'isoler mathématiquement l'indice d'interaction SHAP, qui capture l'effet synergique bidimensionnel pur entre deux variables, soustrait de leurs effets univariés respectifs. Le cas pratique démontre la génération de tracés de dépendance partielle enrichis (SHAP Dependence Plots).[4,5] L'analyse graphique dévoile que le risque prédictif de néphropathie diminue drastiquement de façon non linéaire à mesure que le niveau d'hémoglobine du patient franchit le seuil clinique critique de 12 g/dL. Mais plus fondamentalement, l'incorporation de l'interaction démontre que la variance de cet effet marginal est fortement corrélée à la présence simultanée d'un diabète sucré, illustrant par un dégradé de couleurs que la co-morbidité modifie substantiellement la courbure de la décision algorithmique de XGBoost.[1]

Cas Pratique 4 : Approches Avancées d'Explicabilité

L'investigation de ce rapport s'élargit enfin aux cas d'usage avancés et atypiques de l'apprentissage d'ensemble, ciblant les architectures hybrides qui nécessitent des cadres conceptuels profondément novateurs pour préserver la confiance algorithmique.

L'Explicabilité du Stacking : Le Paradigme XStacking

Le modèle de méta-apprentissage connu sous le nom de Stacking (Stacked Generalization) pousse la logique de combinaison à son paroxysme en superposant hiérarchiquement les prédictions.[1] Cette architecture entraîne en parallèle un panel de modèles de base d'une très forte hétérogénéité algorithmique (par exemple, la juxtaposition d'un Perceptron Multicouche, d'un XGBoost, d'une Forêt Aléatoire et d'une Machine à Vecteurs de Support).[1] Lors de l'inférence, un second algorithme de plus haut niveau, désigné comme le méta-apprenant (fréquemment une régression logistique modélisant le consensus), reçoit en entrée un espace tensoriel réduit constitué exclusivement des prédictions (les vecteurs de probabilités hors-pli ou OOF) produites par la première couche d'apprenants.[1]

Ce processus d'abstraction écrase totalement l'espace dimensionnel des caractéristiques médicales originelles, provoquant une asymétrie d'information fatale à l'explicabilité : l'analyste peut déterminer avec certitude que le méta-apprenant a accordé un poids prépondérant au modèle XGBoost pour établir son diagnostic, mais il ignore totalement sur quelles variables cliniques initiales l'algorithme XGBoost s'est fondé pour émettre sa probabilité.[1]

Le framework novateur XStacking (Explanation-augmented Stacking) propose une solution d'ingénierie élégante à cette cécité interprétative en enrichissant délibérément l'espace de représentation du méta-apprenant.[1] Au cours de la phase de validation croisée hors-pli, la procédure algorithmique de XStacking génère non seulement la matrice des prédictions $\hat{y}_k$ pour chaque modèle de base k, mais elle exécute également en parallèle l'extracteur d'explication approprié pour calculer le vecteur d'attributions des valeurs de Shapley (SHAP) pour chaque instance x.[1] La nouvelle matrice d'apprentissage Z, qui alimentera le méta-modèle, concatène prédictions et causalités sous la forme :

$$Z_{XStacking} = [\hat{y}_1, \ldots, \hat{y}_K, \phi(f_1(x)), \ldots, \phi(f_K(x))]$$

En injectant ces vecteurs d'importances normalisés directement au niveau de la fonction de perte du méta-modèle, la dimension de l'espace latent augmente substantiellement, passant de K (le simple nombre de modèles) à $K(1+$ (où d est le nombre de caractéristiques).[1]

Propriété Structurelle	Stacking Conventionnel	Framework XStacking
Entrées du Méta-Apprenant	Matrice des prédictions OOF $(\hat{y}_1, \ldots, \hat{y}_K$	Vecteurs de prédictions agrégés aux matrices d'attributions SHAP [1]

Dimensionnalité de Niveau 1	K (Nombre de modèles de base)	$K(1+$ (Haute dimension) [1]
Lien avec l'Espace des Caractéristiques	Rompu par le changement de plan tensoriel	Maintenu nativement, traçabilité continue [1]
Bénéfice Prédictif	Modéré (sensible à la colinéarité des prédictions)	Supérieur (discrimination par l'importance des variables, atténuation de la redondance) [2]

Cette augmentation spectaculaire de la densité d'information permet non seulement d'améliorer la discrimination prédictive finale (en prévenant le surapprentissage lié à des modèles dont les probabilités sont fortement corrélées mais justifiées par des motifs erronés), mais elle restaure intégralement l'explicabilité de bout-en-bout du pipeline de machine learning.[2] Sur le cas pratique, le médecin peut auditer la chaîne de décision complète : identifier la forte valeur prédictive accordée à la pression artérielle par le classifieur XGBoost, et comprendre précisément comment le méta-apprenant final a pondéré et arbitré cette information causale face aux déductions contradictoires du réseau de neurones.[1] XStacking démontre ainsi que performance d'ensemble et transparence ne sont pas mutuellement exclusives.[2]

Sélection Dynamique d'Ensemble et Explicabilité Contextuelle

Une autre philosophie d'hybridation des modèles repose sur les techniques de sélection dynamique de classifieurs (Dynamic Ensemble Selection - DES), implémentées en Python via l'excellente bibliothèque DESlib.[50] Plutôt que de recourir à une agrégation statique ou pondérée de l'ensemble de la cohorte de modèles pour évaluer chaque patient, la logique DES s'adapte à la topologie locale des données. Lors de la présentation d'une instance inconnue (un nouveau patient suspecté de CKD), l'algorithme ne sollicite pas le vote de l'intégralité du pool. Il définit en amont une « Région de Compétence » (Region of Competence - RoC) en calculant, via la distance euclidienne, les k-plus proches voisins du patient au sein d'un jeu de données historique de validation (DSEL).[1]

L'exactitude locale de chaque algorithme expert du pool est alors évaluée mathématiquement sur cette région spécifique. Seuls les classifieurs ayant démontré historiquement une compétence absolue sur ce voisinage local sont sélectionnés à la volée pour procéder au vote de classification (en utilisant des algorithmes tels que KNORA-E pour l'élimination ou KNORA-U pour l'union).[1]

L'implémentation de la bibliothèque DESlib dans ce cadre hospitalier procure une forme d'explicabilité par héritage contextuel et par raisonnement basé sur les cas (Case-Based

Reasoning - CBR).[1] L'algorithme justifie son diagnostic non pas en projetant un hyperplan mathématique complexe, mais en identifiant et en extrayant les profils cliniques des patients historiquement comparables figurant dans la région de compétence. L'explication se formalise par l'analogie : le clinicien comprend que l'expert algorithmique X a été mandaté pour prédire le statut rénal de ce patient car il a précédemment diagnostiqué avec succès des profils d'anémie et d'hypertension strictement similaires.[1] Cette transparence par l'exemple (Example-based explanation) résonne particulièrement avec la méthodologie cognitive naturelle du corps médical.[53]

Scénario Contrefactuel : Explications par la Diversité et l'Actionnabilité (DiCE)

Pour conclure ce rapport par une dimension opératoire, il est fondamental de souligner que, bien que les méthodes fondées sur les attributions statistiques (SHAP, LIME, PFI) fournissent une excellente cartographie de l'influence des variables de modélisation, elles demeurent descriptives.[1] Elles ne prescrivent pas de voie de remédiation tangible pour l'utilisateur. L'analyse par la génération d'exemples contrefactuels, introduite et formalisée au travers du framework DiCE (Diverse Counterfactual Explanations de Microsoft), aborde le défi de l'explicabilité sous le prisme puissant de l'optimisation inverse et du recours (recourse).[54]

Face à une instance de patient pronostiquée avec certitude comme positif au développement d'une insuffisance rénale aiguë par le modèle XGBoost, la méthode contrefactuelle ne se contente pas de lister les facteurs de risque. Elle interroge activement la frontière de décision du modèle : "Quelles sont les modifications minimales, cliniquement réalisables, et structurellement diverses des caractéristiques du patient qui forceront l'algorithme à inverser sa prédiction vers un pronostic de patient sain?".[54] DiCE traduit cette interrogation humaine en un problème d'optimisation mathématique multiobjectif : $\arg\min_{x'} d(x, x') + \lambda_1 \mathcal{L}(f(x'), y_{\text{désiré}}) - \lambda_2 \text{Diversité}(x')$ Dans cette formulation, $d(x, x')$ représente la fonction de distance de proximité par rapport au profil original du patient, $\mathcal{L}$ est la perte d'adversialité qui contraint formellement le franchissement de la frontière de classe cible, et le terme de diversité algorithmique (souvent calculé via le déterminant de la matrice de similarité) assure la restitution d'un ensemble hétérogène de scénarios de recours.[54]

Dans la mise en œuvre pratique de ce TP via la classe dice_ml.Dice(), l'algorithme génère des contrefactuels en respectant des contraintes d'immuabilité et de faisabilité physiologique.[54] Par exemple, l'âge et la prédisposition génétique du patient sont fixés comme invariants, seules des caractéristiques comme la pression artérielle, le contrôle glycémique ou le niveau d'hémoglobine sont déclarées modifiables au sein de bornes médicalement réalistes.[56] Le script Python restitue alors une série de plans d'action opposables et cohérents : "Si le taux moyen du débit de filtration glomérulaire (eGFR_mean) de ce patient parvenait à être réévalué

cliniquement de 15.39 mL/min à 25.48 mL/min, de façon isolée, alors le modèle de gradient boosting prédirait formellement l'absence d'insuffisance rénale".[57] Cette dimension éminemment prescriptive et actionnable de l'analyse contrefactuelle s'inscrit au cœur des exigences du RGPD concernant le droit au recours algorithmique, transformant un outil de diagnostic passif en un instrument de planification thérapeutique.[54]

Synthèse Analytique et Résolution du Compromis Performance-Transparence

L'accumulation systématique de ces méthodes pratiques d'évaluation, du modèle le plus élémentaire aux architectures contrefactuelles et méta-apprenantes, conduit indubitablement à devoir affronter un défi épistémologique majeur en apprentissage automatique : l'Effet Rashomon (ou multiplicité des modèles de Breiman).[1] Dans des espaces paramétriques à haute dimension typiques des ensembles de données biomédicales, il existe invariablement de multiples architectures radicalement différentes (Réseaux de neurones denses, XGBoost profond, Forêts Aléatoires étendues, ou EBM) et une myriade de combinaisons d'hyperparamètres capables d'atteindre une erreur de généralisation et une exactitude statistique quasi-identiques (formant le Rashomon set).[1] Paradoxalement, bien que ces modèles convergent vers la même performance globale de diagnostic pour la cohorte CKD, ils parviennent à ce résultat en s'appuyant sur des réseaux de logiques inférentielles diamétralement incompatibles.[1]

Se fier aveuglément à l'analyse de l'importance des caractéristiques par une technique d'explicabilité unique (telle qu'un unique tracé SHAP) appliquée sur le « meilleur » modèle empirique unique crée un biais cognitif redoutable : cela induit le clinicien ou l'auditeur réglementaire à postuler à tort la découverte d'une loi causale absolue dans les données.[1] Face à cette multiplicité, la convergence des efforts d'ingénierie vers le concept de Consensus en XAI (XAI Consensus Training ou agrégation robuste des explications) devient un impératif d'assurance qualité. Le processus itératif développé dans ce rapport préconise le couplage systématique de TreeSHAP avec les ensembles XGBoost, combiné aux modèles de référence nativement interprétables comme l'EBM et validé en aval par l'extraction des règles symboliques SIRUS.[1]

Lorsqu'un biomarqueur tel que l'hémoglobine maintient un profil d'influence causalement convergent et unanime à travers la totalité de l'ensemble des modèles du Rashomon set et résiste à la variabilité des différentes heuristiques d'explicabilité appliquées (l'effet est positif selon LIME, SHAP, EBM et les modèles contrefactuels de DiCE), la robustesse de sa portée inférentielle et causale peut être formellement certifiée.[1] Toute discordance majeure doit quant à elle alerter le data scientist sur l'exploitation probable de corrélations fallacieuses (spurious correlations) ou de failles de données par le modèle, exigeant une révision immédiate de l'ingénierie des caractéristiques.[1]

Le tableau de gouvernance suivant (Tableau 2) formalise l'architecture décisionnelle préconisée pour la sélection et l'implémentation des cadres d'explicabilité pour les systèmes d'ensemble.

Scénario Analytique d'Ingénierie	Contrainte Opérationnelle Dominante	Méthodologie Recommandée	Justification et Garantie Mathématique
Amorçage de Projet Médical ou Financier Critique	Transparence native stricte imposée par les régulateurs, conformité absolue.	**Explainable Boosting Machine (EBM)**	Adopte l'architecture en boîte de verre (Glass-box GA2M). L'influence de chaque variable est exacte. Exactitude AUC empiriquement compétitive et non discriminée face à XGBoost.[1]
Modélisation Héritée (Bagging/Boosting opaque imposé)	Exigence d'une cartographie traçable des caractéristiques garantissant une stricte équité causale globale.	**Analyse par TreeSHAP**	Fondations robustes ancrées en théorie des jeux coopératifs. Algorithme garantissant le calcul exact de l'interaction et de l'efficience unitaire en temps polynomial $O(TLD^2$.[1]
Extraction de Systèmes de Connaissances Experts	Validation humaine requise, cohérence temporelle absolue, intégration aux systèmes experts.	**Règles Stables de l'Algorithme SIRUS**	Stabilise l'extraction aléatoire par un filtrage fréquentiel et une discrétisation par quantiles. Reproductibilité

			mathématique attestée par un score de Dice-Sørensen maximal (>0,95).[1]
Intervention au Niveau de l'Instance Patient	Légalité du droit au recours, actionnabilité médicale, et indication d'un traitement prescriptif.	**Explications Contrefactuelles (DiCE)**	Optimisation mathématique générant des permutations sous contraintes strictes, pointant avec précision les seuls leviers cliniques modifiables permettant l'inversion d'une classification.[54]
Déploiement Embarqué ou Sous Contrainte de Temps Réel	Optimisation drastique du temps d'inférence (latence), mémoire extrêmement contrainte.	**Distillation de Connaissances Symbolique**	Processus d'apprentissage d'un arbre étudiant sur-paramétré capable de reproduire fidèlement la distribution "soft-label" non linéaire captée par la forêt aléatoire enseignante.[1]
Architecture de Méta-Apprentissage Profonde	Préservation intégrale du signal causal à travers des réseaux décisionnels superposés.	**Framework XStacking**	Intégration novatrice des valeurs et attributions SHAP au sein des méta-caractéristiques dimensionnelles, prévenant la cécité de la dernière couche.[1]

En conclusion de ces travaux, la prétendue dichotomie axiomatique opposant la précision prédictive d'un système multi-classifieurs complexe à sa capacité d'interprétation humaine se révèle ne plus constituer une frontière théorique infranchissable en science des données. Elle résultait fondamentalement d'un paradigme d'ingénierie algorithmique antérieur qui sacrifiait structurellement l'exigence explicative au profit de la minimisation hâtive des fonctions de perte.[1]

S'il est exact que l'apprentissage d'ensemble génère mécaniquement des structures de boîtes noires par sa quête itérative de la diversité et de l'hyper-spécialisation locale des modèles de base [1], l'orchestration croisée des techniques contemporaines de XAI démontre la maturité de la discipline. De l'exactitude des algorithmes polynomiaux TreeSHAP aptes à désamorcer analytiquement la complexité de l'agrégation, à la stabilité mathématique des extracteurs de règles symboliques SIRUS, en passant par l'actionnabilité pragmatique des modèles de recours contrefactuels de DiCE et l'innovation par l'apprentissage méta-enrichi du XStacking, les data scientists disposent d'un arsenal méthodologique complet.[1] Plus fondamentalement, l'émergence de modèles nativement interprétables atteignant l'état de l'art, à l'instar des Explainable Boosting Machines (EBM), confirme l'avènement d'une conception structurelle où la haute performance n'élude pas la clarté.[1]

L'intégration de l'apprentissage automatique aux chaînes de valeur décisionnelles critiques, qu'elles concernent le diagnostic médical de pathologies chroniques ou l'évaluation automatisée de risques, exige que l'explicabilité transcende le simple rôle d'outil d'audit algorithmique post-hoc.[1] Elle constitue l'interface universelle de validation éthique, scientifique et réglementaire, agissant comme le garant ultime que la pure performance statistique demeurera invariablement subordonnée à l'intelligibilité de l'expert humain.[1] L'ingénierie future des modèles d'ensemble à grande échelle devra impérativement s'inscrire dans cet écosystème d'hybridation, assurant de manière indivisible la synergie entre la redoutable puissance discriminative des foules algorithmiques et la transparence d'un raisonnement causal responsable et auditable.

Works cited

1. main2.pdf
2. XStacking: Explanation-Guided Stacked Ensemble Learning - arXiv, accessed March 8, 2026, https://arxiv.org/pdf/2507.17650
3. Interpretable machine learning for chronic kidney disease prediction: Insights from SHAP and LIME analyses - Our journal portfolio - PLOS, accessed March 8, 2026, https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0343205
4. Explainable artificial intelligence (XAI) for predicting the need for intubation in methanol-poisoned patients: a study comparing deep and machine learning models - PMC, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC11231277/
5. Interpreting artificial intelligence models: a systematic review on the application

of LIME and SHAP in Alzheimer's disease detection - PMC, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10997568/
6. Explainable Machine Learning Model for Chronic Kidney Disease Prediction - MDPI, accessed March 8, 2026, https://www.mdpi.com/1999-4893/17/10/443
7. Chronic Kidney Disease - UCI Machine Learning Repository, accessed March 8, 2026, https://archive.ics.uci.edu/dataset/336/chronic+kidney+disease
8. Building a Chronic Kidney Disease Prediction Model Using Python and Machine Learning, accessed March 8, 2026, https://medium.com/@1032211306/building-a-chronic-kidney-disease-prediction-model-using-python-and-machine-learning-4f8a546e6c25
9. Interpretable machine learning for chronic kidney disease prediction: Insights from SHAP and LIME analyses - PubMed, accessed March 8, 2026, https://pubmed.ncbi.nlm.nih.gov/41747002/
10. Accuracy is not enough: explainable boosting machine model and identification of candidate biomarkers for real-time sepsis risk assessment in the emergency department - PMC, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12664189/
11. Explainable AI for Chronic Kidney Disease Prediction in Medical IoT: Integrating GANs and Few-Shot Learning - PMC, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12025083/
12. Machine Learning Techniques in Chronic Kidney Diseases: A Comparative Study of Classification Model Performance - PMC, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12304504/
13. Investigation on explainable machine learning models to predict chronic kidney diseases, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10866953/
14. 1.10. Decision Trees — scikit-learn 1.8.0 documentation, accessed March 8, 2026, https://scikit-learn.org/stable/modules/tree.html
15. Decision Trees and Random Forests - explained with Python implementation., accessed March 8, 2026, https://towardsdatascience.com/decision-trees-and-random-forests-explained-with-python-implementation-e5ede021a000/
16. How to Visualize a Decision Tree from a Random Forest in Python using Scikit-Learn, accessed March 8, 2026, https://medium.com/data-science/how-to-visualize-a-decision-tree-from-a-random-forest-in-python-using-scikit-learn-38ad2d75f21c
17. interpretml/interpret: Fit interpretable models. Explain blackbox machine learning. - GitHub, accessed March 8, 2026, https://github.com/interpretml/interpret
18. Explainable Boosting Machine — InterpretML documentation, accessed March 8, 2026, https://interpret.ml/docs/ebm.html
19. Train regression models using explainable boosting machines (preview) - Microsoft Fabric, accessed March 8, 2026, https://learn.microsoft.com/en-us/fabric/data-science/explainable-boosting-machines-regression
20. WO2025084987A1 - Systems and methods for predicting kidney conditions -

Google Patents, accessed March 8, 2026, https://patents.google.com/patent/WO2025084987A1/en?inventor=Koh+Yau+Luong&oq=Koh+Yau+Luong
21. Hands-on XAI with SHAP and LIME - Kaggle, accessed March 8, 2026, https://www.kaggle.com/code/yatrikshah/hands-on-xai-with-shap-and-lime
22. Trusting SHAP and LIME the Right Way - Medium, accessed March 8, 2026, https://medium.com/@pacosun/trusting-shap-and-lime-the-right-way-ccab78f0316b
23. Model Explainability: LIME & SHAP | by Beverly Wang - Medium, accessed March 8, 2026, https://beverly-wang0005.medium.com/model-explainability-lime-shap-55c8bf644ce0
24. cloudera/CML_AMP_Explainability_LIME_SHAP: Learn how to explain ML models using LIME and SHAP. - GitHub, accessed March 8, 2026, https://github.com/cloudera/CML_AMP_Explainability_LIME_SHAP
25. ryuzaki-ved/ckd_detection: This project focuses on predicting Chronic Kidney Disease (CKD) using neural networks. It involves comprehensive data preprocessing, exploratory data analysis, and model interpretability to provide a robust classification solution based on health records. - GitHub, accessed March 8, 2026, https://github.com/ryuzaki-ved/ckd_detection
26. Stacking Ensemble Machine Learning With Python - MachineLearningMastery.com, accessed March 8, 2026, https://machinelearningmastery.com/stacking-ensemble-machine-learning-with-python/
27. Introduction to Ensembling/Stacking in Python - Kaggle, accessed March 8, 2026, https://www.kaggle.com/code/arthurtok/introduction-to-ensembling-stacking-in-python
28. Building Random Forest From Scratch in Python - Medium, accessed March 8, 2026, https://medium.com/@cristianleo120/building-random-forest-from-scratch-in-python-16d004982788
29. Machine Learning Hybrid Model for the Prediction of Chronic Kidney Disease - PMC, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10030216/
30. Random Forest in Python and coding it with Scikit-learn (tutorial) - Data36, accessed March 8, 2026, https://data36.com/random-forest-in-python/
31. From Local Explanations to Global Understanding with Explainable AI for Trees - PMC - NIH, accessed March 8, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC7326367/
32. SIRUS.jl: Interpretable Machine Learning via Rule Extraction - the University of Groningen research portal, accessed March 8, 2026, https://research.rug.nl/en/publications/sirusjl-interpretable-machine-learning-via-rule-extraction/
33. SIRUS: Stable and Interpretable RUle Set for Classification, accessed March 8, 2026, https://perso.lpsm.paris/~biau/BIAU/bbds.pdf

34. [ANN] SIRUS.jl v1.2: Interpretable Machine Learning via Rule Extraction - Julia Discourse, accessed March 8, 2026, https://discourse.julialang.org/t/ann-sirus-jl-v1-2-interpretable-machine-learning-via-rule-extraction/100932
35. A Unified Approach to Extract Interpretable Rules from Tree Ensembles via Integer Programming - arXiv.org, accessed March 8, 2026, https://arxiv.org/html/2407.00843v3
36. Article and book summaries by Vincent Zoonekynd (2025-10), accessed March 8, 2026, http://zoonek.free.fr/Ecrits/articles.pdf
37. GitHub - csinva/imodels: Interpretable ML package for concise, transparent, and accurate predictive modeling (sklearn-compatible)., accessed March 8, 2026, https://github.com/csinva/imodels
38. A Unified Approach to Extract Intepretable Rules from Tree Ensembles via Integer Programming - arXiv.org, accessed March 8, 2026, https://arxiv.org/html/2407.00843v1
39. A New Method to Compare the Interpretability of Rule-Based Algorithms - MDPI, accessed March 8, 2026, https://www.mdpi.com/2673-2688/2/4/37
40. Distilling a Random Forest to a single DecisionTree - Machine Learning Blog, accessed March 8, 2026, http://www.clungu.com/Distilling_a_Random_Forest_with_a_single_DecisionTree/
41. Random-Forest Distillation: Theory and Practice - Emergent Mind, accessed March 8, 2026, https://www.emergentmind.com/topics/random-forest-distillation
42. Knowledge distillation from random forests : r/learnmachinelearning - Reddit, accessed March 8, 2026, https://www.reddit.com/r/learnmachinelearning/comments/bdi3wv/knowledge_distillation_from_random_forests/
43. Using Explainable Boosting Machine to Compare Idiographic and Nomothetic Approaches for Ecological Momentary Assessment Data - ResearchGate, accessed March 8, 2026, https://www.researchgate.net/publication/359767947_Using_Explainable_Boosting_Machine_to_Compare_Idiographic_and_Nomothetic_Approaches_for_Ecological_Momentary_Assessment_Data
44. A Gentle Introduction to SHAP for Tree-Based Models - MachineLearningMastery.com, accessed March 8, 2026, https://machinelearningmastery.com/a-gentle-introduction-to-shap-for-tree-based-models/
45. Explaining Model Pipelines With InterpretML | by Marius Vadeika - Medium, accessed March 8, 2026, https://medium.com/@mariusvadeika/explaining-model-pipelines-with-interpretml-a9214f75400b
46. GitHub - vecxoz/vecstack: Python package for stacking (machine learning technique), accessed March 8, 2026, https://github.com/vecxoz/vecstack
47. Comprehensive Analysis of Random Forest and XGBoost Performance with SMOTE, ADASYN, and GNUS Under Varying Imbalance Levels - MDPI, accessed March 8, 2026, https://www.mdpi.com/2227-7080/13/3/88

48. Graphical abstract illustrates RocketStack framework - arXiv.org, accessed March 8, 2026, https://arxiv.org/html/2506.16965v3
49. XStacking: Explanation-Augmented Stacking - Emergent Mind, accessed March 8, 2026, https://www.emergentmind.com/topics/explanation-augmented-stacking-xstacking
50. DESlib: A Dynamic ensemble selection library in Python - Journal of Machine Learning Research, accessed March 8, 2026, https://jmlr2020.csail.mit.edu/papers/volume21/18-144/18-144.pdf
51. Dynamic Ensemble Selection (DES) for Classification in Python - Machine Learning Mastery, accessed March 8, 2026, https://machinelearningmastery.com/dynamic-ensemble-selection-in-python/
52. Tutorial — deslib 0.4.dev documentation, accessed March 8, 2026, https://deslib.readthedocs.io/en/latest/user_guide/tutorial.html
53. From dynamic classifier selection to dynamic ensemble selection - biz.uiowa.edu, accessed March 8, 2026, https://www.biz.uiowa.edu/faculty/nstreet/ko07.pdf
54. interpretml/DiCE: Generate Diverse Counterfactual Explanations for any machine learning model. - GitHub, accessed March 8, 2026, https://github.com/interpretml/DiCE
55. 15 Counterfactual Explanations – Interpretable Machine Learning - Christoph Molnar, accessed March 8, 2026, https://christophm.github.io/interpretable-ml-book/counterfactual.html
56. Quick introduction to generating counterfactual explanations using ..., accessed March 8, 2026, https://interpret.ml/DiCE/notebooks/DiCE_getting_started.html
57. Predicting chronic kidney disease progression using small pathology datasets and explainable machine learning models | medRxiv, accessed March 8, 2026, https://www.medrxiv.org/content/10.1101/2024.04.08.24305414v1.full-text
58. Distilling a Random Forest to a single DecisionTree, does it make sense?, accessed March 8, 2026, https://datascience.stackexchange.com/questions/121686/distilling-a-random-forest-to-a-single-decisiontree-does-it-make-sense
59. Explainable Boosting machines for Tabular data - Kaggle, accessed March 8, 2026, https://www.kaggle.com/code/parulpandey/explainable-boosting-machines-for-tabular-data